



16.63 - Procesamiento de Señales e Imágenes Biomédicas

TPI - Procesamiento de Imágenes Biomédicas

Rosario Ballester Villafañe (Legajo: 62648)

Matilde Sanches Esteves Rosado (Legajo: 69216)

Agustin Rodriguez Torricelli (Legajo: 64501)

Índice

Resumen.....	3
1. Introducción.....	4
1.1 La anemia como problema de salud público global.....	4
1.2 El frotis de sangre periférica: pilar diagnóstico irremplazable.....	4
1.3 Desafíos del diagnóstico manual y necesidad de automatización.....	4
1.4 Diagnóstico Computarizado por Imágenes: Estado del Arte.....	5
1.5 Objetivos.....	5
2. Materiales y Métodos.....	6
2.1 Instalación de librerías y descarga del dataset.....	6
2.2 Carga de imágenes AneRBC-II.....	6
2.3 Preprocesamiento.....	6
2.4 Segmentación de eritrocitos.....	7
2.5 Extracción de características por célula.....	8
2.6 Agregación por imagen.....	9
2.7 Procesamiento del dataset de referencia.....	9
2.8 Módulo de validación con ground truth.....	10
2.9 Resumen estadístico por clase.....	10
2.10 Modelo de diagnóstico por centroides normalizados.....	10
2.11 Diagnóstico de imagen nueva.....	11
3. Resultados.....	11
4. Conclusiones.....	12
Anexo.....	13
Anexo 1: Parámetros morfológicos clave extraídos de la literatura.....	13
Anexo 2: Materiales y Métodos.....	13
Bibliografía.....	16

Resumen

En este trabajo se desarrolló un sistema computacional de apoyo para el análisis de imágenes microscópicas de frotis sanguíneo, orientado a la clasificación automática de imágenes compatibles con patrón anémico o sano. Para ello, se utilizó el dataset AneRBC, específicamente el subconjunto AneRBC-II, debido a que sus imágenes presentan mayor aumento y menor cantidad de eritrocitos por campo, lo que permite reducir el costo computacional del procesamiento. El pipeline implementado incluyó etapas de preprocesamiento, segmentación de eritrocitos, extracción de características celulares, agregación de parámetros a nivel de imagen, construcción de un modelo de clasificación binaria basado en centroides normalizados y validación con imágenes etiquetadas.

La segmentación se realizó mediante umbralización de Otsu, operaciones morfológicas, transformada de distancia y algoritmo Watershed, con el objetivo de separar los eritrocitos del fondo y dividir células en contacto. A partir de las regiones segmentadas se extrajeron características morfológicas, de intensidad, color, textura e índice de palidez central. Posteriormente, dichas características fueron agregadas estadísticamente para construir un descriptor global por imagen. El clasificador se basó en la distancia euclídea a los centroides de las clases Anemic y Healthy en un espacio normalizado. Finalmente, el sistema fue evaluado sobre un conjunto de validación independiente y se implementó un módulo de análisis para imágenes nuevas, capaz de mostrar la clasificación automática, las métricas principales y las visualizaciones asociadas al proceso de segmentación.

1. Introducción

1.1 La anemia como problema de salud público global

La anemia constituye uno de los trastornos hematológicos de mayor relevancia sanitaria a nivel mundial, tanto por su elevada prevalencia como por sus consecuencias clínicas, funcionales y sociales. De acuerdo con la Organización Mundial de la Salud, se trata de un problema grave de salud pública que afecta especialmente a mujeres en edad reproductiva, embarazadas y niños pequeños. En términos generales, la anemia se define como una disminución de la concentración de hemoglobina o de la masa eritrocitaria por debajo de los valores considerados normales para una determinada edad, sexo y condición fisiológica.

El eritrocito maduro es una célula altamente especializada cuya función principal es el transporte de oxígeno mediante la hemoglobina. Su morfología característica, de disco bicóncavo, favorece tanto el intercambio gaseoso como la deformabilidad necesaria para atravesar la microcirculación. Por este motivo, las alteraciones en su número, tamaño, forma, coloración o contenido de hemoglobina pueden tener impacto directo sobre la oxigenación tisular. En la práctica clínica, el abordaje inicial de la anemia se basa en la integración de la historia clínica, el examen físico y estudios complementarios básicos, principalmente el hemograma, los índices eritrocitarios, el recuento de reticulocitos, los parámetros del metabolismo del hierro y el examen del frotis de sangre periférica.

1.2 El frotis de sangre periférica: pilar diagnóstico irremplazable

A pesar del avance de los autoanalizadores hematológicos, el frotis de sangre periférica continúa siendo una herramienta fundamental en el diagnóstico hematológico. Mientras que el hemograma aporta información cuantitativa sobre parámetros como hemoglobina, hematocrito, volumen corpuscular medio, hemoglobina corpuscular media y concentración de hemoglobina corpuscular media, el frotis permite evaluar directamente la morfología celular. Esta observación microscópica conserva un valor diagnóstico irremplazable, ya que permite identificar alteraciones eritrocitarias que no siempre pueden interpretarse de manera completa a partir de los parámetros numéricos.

El análisis morfológico del frotis resulta especialmente relevante en el estudio de las anemias, debido a que permite reconocer cambios en el tamaño, la forma, la coloración, la distribución y la presencia de inclusiones eritrocitarias. De esta forma, el frotis no sólo complementa al hemograma, sino que permite contextualizar los resultados cuantitativos dentro de una evaluación morfológica más amplia.

En los laboratorios modernos, los analizadores hematológicos han permitido optimizar tiempos y reducir errores analíticos, pero no reemplazan completamente la revisión microscópica. El estudio morfológico realizado por personal entrenado sigue siendo esencial para confirmar hallazgos, validar resultados automatizados y aportar información diagnóstica que puede modificar la conducta clínica.

1.3 Desafíos del diagnóstico manual y necesidad de automatización

Si bien el análisis microscópico del frotis posee un alto valor diagnóstico, también presenta limitaciones importantes. La evaluación manual depende de la experiencia del observador, requiere tiempo, demanda personal especializado y puede verse afectada por fatiga visual o variabilidad interobservador. Además, muchas decisiones morfológicas se basan en criterios descriptivos y cualitativos, lo que puede dificultar la reproducibilidad entre distintos operadores o laboratorios. Esta problemática ha impulsado la necesidad de estandarizar la nomenclatura, la graduación de los hallazgos y los criterios de informe de la morfología eritrocitaria.

En este contexto, el procesamiento digital de imágenes biomédicas surge como una alternativa de gran interés para asistir el análisis del frotis sanguíneo. A partir de imágenes microscópicas, es posible aplicar técnicas de preprocesamiento, segmentación, extracción de características y clasificación

automática. Estas herramientas permiten transformar observaciones visuales subjetivas en parámetros cuantificables, tales como área, perímetro, circularidad, excentricidad, solidez, intensidad, textura e índice de palidez central. De esta manera, características asociadas al tamaño, la forma y la coloración eritrocitaria pueden analizarse de forma objetiva y reproducible.

1.4 Diagnóstico Computarizado por Imágenes: Estado del Arte

Los sistemas de clasificación automática de eritrocitos en frotis de sangre periférica han evolucionado desde enfoques estadísticos lineales hasta arquitecturas de aprendizaje profundo. Mejia et al. (2016) desarrollaron una aplicación en MATLAB que combina procesamiento digital de imágenes con una red neuronal artificial (RNA) de retropropagación para clasificar eritrocitos en siete categorías: normocitos, dacrocitos, eliptocitos, equinocitos, esferocitos, esquistocitos y rollos, alcanzando una tasa de aciertos del 97.3% sobre datos de validación. Este trabajo constituye el antecedente metodológico más directo de nuestro pipeline. Más recientemente, Mondal et al. (2025) propusieron el framework BloodCell-Net, que combina U-Net para segmentación semántica, el algoritmo Watershed para separar células superpuestas, y una red neuronal convolucional liviana (LWCNN) con 653,129 parámetros entrenables para clasificar nueve tipos celulares (incluyendo eritrocitos, eritroblastos, neutrófilos, basófilos, eosinófilos, linfocitos, monocitos, granulocitos inmaduros y plaquetas). El sistema logró 97.10% de exactitud promedio con validación cruzada de 5 pliegues, con una segmentación U-Net de 98.23% de exactitud a nivel de píxel.

La revisión de la literatura permitió identificar los parámetros morfológicos con mayor poder discriminatorio para la clasificación eritrocitaria. Estos parámetros, que fundamentan las decisiones de diseño de nuestro pipeline, se detallan en la *Tabla 1* presente en el *Anexo 1*.

1.5 Objetivos

El objetivo general de este trabajo es desarrollar un sistema computacional de apoyo para el análisis de imágenes microscópicas de frotis sanguíneo, orientado a la clasificación automática de imágenes compatibles con patrón anémico o sano a partir de características eritrocitarias. Para ello, se plantean los siguientes objetivos específicos:

- Implementar un pipeline de preprocesamiento y segmentación de eritrocitos en imágenes de frotis sanguíneo, que permita identificar regiones celulares de interés y separar, en la medida de lo posible, células individuales.
- Extraer un conjunto representativo de características por célula, incluyendo parámetros morfológicos, de intensidad, color, textura e índice de palidez central.
- Agregar las características celulares a nivel de imagen, con el fin de construir un descriptor global representativo de cada muestra analizada.
- Diseñar e implementar un modelo de clasificación binaria entre imágenes compatibles con patrón anémico y sano, basado en la comparación de descriptores mediante centroides de referencia.
- Validar el desempeño del sistema utilizando un subconjunto de imágenes con etiquetas conocidas, reportando métricas estándar de clasificación.
- Desarrollar un módulo de análisis para imágenes nuevas, capaz de procesar una imagen ingresada por el usuario, generar la clasificación automática y visualizar los resultados principales de segmentación, extracción de características y comparación con las referencias.

2. Materiales y Métodos

A lo largo del trabajo se implementó un pipeline modular para la clasificación eritrocitaria en frotis de sangre periférica. A continuación se describe en detalle cada módulo, su función y su fundamentación bibliográfica.

2.1 Instalación de librerías y descarga del dataset

Este primer bloque configura el entorno de ejecución en Google Colab con Python 3. Instala las dependencias necesarias (**kagglehub** para la descarga automatizada del dataset y **openpyxl** para la exportación de resultados en formato Excel) e importa el conjunto completo de librerías científicas utilizadas a lo largo del pipeline. Las principales librerías importadas se encuentran presentes en la *Tabla 2* correspondiente al *Anexo 2*.

Se utilizó el dataset “AneRBC: Anemia Diagnosis Using RBC Images” disponible en Kaggle (<https://www.kaggle.com/datasets/jocelyndumlao/anerbc-anemia-diagnosis-using-rbc-images>). El mismo está compuesto por imágenes microscópicas de frotis sanguíneos orientadas al análisis de eritrocitos para el estudio de anemia. La base se organiza en dos carpetas principales, AneRBC-I y AneRBC-II; dentro de cada una se encuentran carpetas correspondientes a individuos con anemia y a individuos sanos. En cada grupo se incluyen las imágenes originales del frotis, que fueron utilizadas como entrada para el posterior desarrollo del trabajo.

2.2 Carga de imágenes AneRBC-II

Este módulo localiza el directorio principal **AneRBC_dataset** dentro de la ruta descargada y selecciona el subconjunto **AneRBC-II**, utilizado para reducir el costo computacional debido a que sus imágenes presentan mayor aumento y, por lo tanto, menor cantidad de eritrocitos por campo. Luego identifica las carpetas de individuos con anemia y sanos, y construye el diccionario **image_paths**, con las claves **Anemic** y **Healthy**, donde se almacenan las rutas ordenadas de las imágenes originales. Además, filtra los archivos según extensiones válidas y verifica la existencia de los directorios esperados, centralizando así el acceso al dataset y dejando organizada la entrada para las etapas posteriores del pipeline.

2.3 Preprocesamiento

El preprocesamiento constituye la primera etapa de transformación de la imagen cruda y resulta fundamental para mejorar la calidad de las etapas posteriores del pipeline. En este trabajo se implementaron dos ramas diferenciadas: una orientada a la segmentación de eritrocitos y otra destinada a la extracción de características. Esta separación responde a que ambas tareas requieren condiciones distintas de contraste, suavizado y preservación de la información visual.

preprocess_for_analysis()

Esta función prepara la imagen para la posterior extracción de características de intensidad, color y textura. Para ello, primero aplica un suavizado gaussiano ligero con un kernel de 5×5 y $\sigma=1$, con el objetivo de reducir ruido de alta frecuencia sin perder información relevante de los bordes celulares. Luego convierte la imagen al espacio de color LAB, donde la luminosidad queda separada de los componentes cromáticos, y aplica CLAHE sobre el canal L con clipLimit=2.0 y tile 8×8 para mejorar el contraste local. Finalmente, la imagen se reconvierte a RGB, conservando una representación adecuada para el cálculo posterior de características morfológicas, cromáticas y texturales de los eritrocitos.

`preprocess_for_segmentation()`

La función prepara la imagen para la etapa de segmentación, generando una versión en escala de grises adecuada para la umbralización y detección de contornos celulares. Primero aplica CLAHE sobre el canal L del espacio LAB, utilizando un `clipLimit=1.5` menor que en la rama de análisis para mejorar el contraste local sin saturar los bordes de los eritrocitos. Luego convierte la imagen mejorada a escala de grises y aplica un filtro de mediana de 5×5 , que permite reducir ruido impulsivo o píxeles aislados preservando mejor los límites celulares. Como salida, devuelve tanto la imagen RGB mejorada como el mapa de grises filtrado, que será utilizado directamente como entrada para la umbralización de Otsu.

2.4 Segmentación de eritrocitos

La segmentación constituye una de las etapas centrales del pipeline, ya que permite identificar los eritrocitos dentro de la imagen y separar las regiones celulares del fondo. La calidad de esta etapa condiciona directamente la validez de las características extraídas posteriormente: una célula mal segmentada puede generar medidas morfológicas, de intensidad o textura incorrectas. El módulo implementa cuatro funciones que se encadenan para resolver los principales desafíos de la segmentación de eritrocitos: separación del fondo, separación de células tocantes y filtrado de artefactos

`get_rbc_binary_mask()`

Genera la máscara binaria inicial mediante el método de umbralización de Otsu. Dado que los eritrocitos son más oscuros que el fondo en imágenes de frotis teñidos con Giemsa, la máscara se obtiene como los píxeles por debajo del umbral calculado ($\text{gray} < \text{thresh}$). El proceso completo es:

- Umbralización de Otsu: método global que minimiza la varianza intra-clase, adecuado cuando existe bimodalidad clara en el histograma (fondo vs. células).
- Cierre morfológico (disco de radio 2 px): rellena pequeñas discontinuidades en los contornos de las células sin alterar su forma general.
- Relleno de agujeros binarios (`binary_fill_holes`): elimina huecos internos causados por el área de palidez central de los eritrocitos normocíticos.
- Eliminación de objetos pequeños (`min_area=120 px²`): descarta artefactos y ruido de baja área.
- Eliminación de agujeros pequeños: refina la máscara final.
- Eliminación opcional de células tocando el borde (`clear_border`): configurable según la necesidad de análisis

`split_touching_cells()`

Resuelve el problema de eritrocitos solapados o en contacto mediante el algoritmo Watershed aplicado sobre la transformada de distancia euclidiana. El procedimiento consta de cuatro pasos:

- Cálculo de la transformada de distancia euclidiana (EDT): cada píxel activo recibe el valor de su distancia al borde más cercano de la máscara. Los máximos locales corresponden a los centros de masa de las células.
- Suavizado gaussiano de la EDT ($\text{sigma}=1.2$): evita la detección de múltiples máximos espurios dentro de una misma célula causados por irregularidades superficiales.
- Detección de máximos locales (`peak_local_max`, `min_distance=10 px`): cada máximo representa un marcador de célula individual.

- Algoritmo Watershed inverso sobre la EDT suavizada: el flood-fill se propaga desde los marcadores hacia el exterior. Las líneas de cresta de la transformada de distancia se convierten en las fronteras entre células. El uso de Watershed sobre la EDT (en lugar de sobre el gradiente de intensidad) es la estrategia estándar para separar objetos convexos o semiesféricos como eritrocitos, y su implementación aquí es metodológicamente correcta.

`filter_regions()`

Tras el Watershed, el mapa de etiquetas puede contener regiones espurias. Esta función aplica un filtro morfológico multi-criterio para conservar únicamente las regiones compatibles con eritrocitos reales. Los criterios de retención se encuentran presentes en la *Tabla 3 del Anexo 2*.

`segment_erythrocytes()` – Función integradora

Convoca las tres funciones anteriores y aplica el filtrado morfológico en dos niveles de permisividad diferenciados por su propósito:

- Nivel permisivo (`labels_count / regions_count`): parámetros menos restrictivos (`min_area=100`, `min_circularity=0.20`) destinados al conteo de candidatos y estimación de densidad celular. Maximiza la sensibilidad (recall) en la detección.
- Nivel estricto (`labels_features / regions_features`): parámetros más exigentes (`min_area=150`, `min_circularity=0.45`, `min_solidity=0.75`) destinados a la extracción de características morfológicas. Maximiza la precisión para evitar que artefactos contaminen el vector de features.

La función devuelve un diccionario completo con todas las representaciones intermedias (máscara binaria, mapa de distancia, marcadores, etiquetas Watershed, regiones permisivas y estrictas), lo que permite tanto el diagnóstico como la visualización detallada del proceso.

2.5 Extracción de características por célula

Por cada eritrocito segmentado (nivel estricto) se extrae un vector de 22 características organizadas en cinco categorías, capturando distintas dimensiones de la apariencia celular con relevancia diagnóstica documentada en la literatura hematológica.

`compute_circularity()`

Calcula la circularidad mediante la fórmula isoperimétrica estándar: $C = 4p \cdot A / P^2$, donde A es el área en píxeles y P el perímetro. El valor 1 corresponde a un círculo perfecto; valores menores indican irregularidades. En el contexto de la anemia, los eritrocitos presentan alteraciones que reducen la circularidad media. La función incluye protección ante perímetro nulo (`return np.nan`), garantizando robustez numérica.

`compute_central_pallor()`

Estima el Índice de Palidez Central (IPC), característica de alta relevancia clínica. En eritrocitos normales, existe una zona central más clara (área de palidez central) que representa aproximadamente el tercio central del disco. El método implementado aplica una erosión morfológica (disco de radio 3 px) sobre la máscara de la célula para obtener la zona central, y calcula la máscara periférica como la diferencia con el borde. El IPC se define como el cociente entre la intensidad media central y la intensidad media periférica. Valores IPC mayores a 1 indican mayor claridad central (palidez presente); valores IPC menores a 1 indican distribución homogénea de intensidad.

`compute_glcm_features()`

Extrae características de textura mediante la Matriz de Co-ocurrencia de Niveles de Gris (GLCM). La GLCM describe cómo se distribuyen espacialmente las parejas de niveles de gris en una imagen. Las tres características calculadas son:

- **Contraste (contrast):** mide la diferencia local entre píxeles vecinos. Valores altos indican texturas rugosas; bajos, texturas suaves. En eritrocitos hipocrónicas el interior más uniforme reduce el contraste.
- **Homogeneidad (homogeneity):** inversa del contraste; alta en texturas uniformes. Complementa la información del contraste.
- **Energía (energy):** suma de los cuadrados de los elementos de la GLCM; alta energía indica textura periódica o constante. Los niveles se reducen a 8 (normalización al rango [0,7]) para aumentar la robustez ante variaciones de iluminación entre imágenes. El ángulo único de 0° (horizontal) y distancia de 1 px son configuraciones estándar para análisis de texturas celulares

`extract_cell_features()` – Función principal

Itera sobre cada región en el mapa de etiquetas estricto y llama a las funciones auxiliares para construir un diccionario por célula. El vector completo de 22 características extraídas se muestra en la *Tabla 4* presente en el *Anexo 2*.

2.6 Agregación por imagen

El clasificador opera a nivel de imagen completa, no de célula individual. Por lo tanto, es necesario condensar el DataFrame de N filas (una por célula) en un único vector representativo de la imagen. La función `aggregate_image_features()` realiza esta operación calculando seis estadísticos descriptivos por cada una de las 22 features celulares. Los valores estadísticos se presentan en la *Tabla 5* del *Anexo 2*.

Entre estos parámetros se encuentra presente el coeficiente de variación (CV): al ser una medida de dispersión normalizada por la media, permite comparar la variabilidad de features con distintas unidades y magnitudes. El resultado final es un diccionario con 132 features agregadas (22 features × 6 estadísticos), más el conteo de candidatos y el número de células utilizadas para features, totalizando más de 134 variables por imagen.

2.7 Procesamiento del dataset de referencia

La función `process_all_images_summary_only()` aplica el pipeline completo (segmentación, extracción y agregación) a cada imagen del conjunto de referencia (N_REFERENCE_PER_CLASS = 250) y construye el DataFrame de referencia que servirá de base para el modelo de diagnóstico. Los aspectos técnicos más relevantes de su implementación son:

- **No acumulación del DataFrame por célula:** para cada imagen se computa el DataFrame celular y se agrega inmediatamente, descartando los datos crudos por célula. Esta decisión reduce drásticamente el consumo de memoria RAM
- **Manejo de excepciones por imagen:** cualquier error durante el procesamiento de una imagen individual se captura en un bloque try/except, registra en `df_ref_errors` y permite continuar el procesamiento del resto del conjunto. Esto garantiza que errores puntuales (imagen corrupta, segmentación fallida) no aborten la ejecución completa.
- **Reporte de progreso:** imprime el avance cada 25 imágenes, facilitando el monitoreo en sesiones largas.
- **Exportación dual CSV/Excel:** los resultados se persisten en ambos formatos para compatibilidad con distintas herramientas de análisis.

2.8 Módulo de validación con ground truth

La función `validate_model()` evalúa el desempeño del clasificador sobre un conjunto de imágenes con etiquetas reales conocidas, completamente independiente del conjunto de referencia. El conjunto de validación comienza en el índice `offset = N_REFERENCE_PER_CLASS`, asegurando que ninguna imagen de validación haya sido utilizada para construir el modelo.

En cuanto al procedimiento de validación, en primer lugar, para cada imagen del conjunto de validación, se aplica el pipeline completo (segmentación, extracción, agregación y clasificación). Luego se compara la clase predicha con la etiqueta verdadera y se registra si la clasificación fue correcta. Por último, se acumulan los resultados en un DataFrame que incluye: ruta de imagen, clase real, clase predicha, score anémico y confianza. Las métricas calculadas en esta etapa se encuentran presentes en la *Tabla 6* del *Anexo 2*. Entre las distintas métricas se encuentra el recall (sensibilidad), esta suele ser la métrica más crítica: un falso negativo tiene consecuencias clínicas más severas que un falso positivo. La incorporación de la especificidad junto a las demás métricas refleja una comprensión adecuada del problema de clasificación binaria.

La función también calcula y exhibe la matriz de confusión completa (TP, FP, FN, TN), cuya interpretación es fundamental para entender el comportamiento diferencial del clasificador por clase.

2.9 Resumen estadístico por clase

Este módulo provee herramientas de análisis exploratorio para comprender las diferencias entre las distribuciones de features en ambas clases.

`generate_summary_by_class()`

Genera un DataFrame pivotado en el que cada fila corresponde a una clase (Anemic/Healthy) y cada columna a una combinación feature×estadístico. Calcula cinco estadísticos: media, desvío, mediana, mínimo y máximo para todas las features numéricas del DataFrame de referencia, excluyendo columnas de índice y dimensión de imagen. El resultado se exporta en CSV y Excel.

`compare_classes()`

Calcula la diferencia en las medias de cada feature entre ambas clases, tanto en valor absoluto como en porcentaje relativo respecto a la clase Healthy. Ordena las features de mayor a menor diferencia relativa, identificando así las features más discriminativas del clasificador. Esta tabla es de gran utilidad para análisis posterior y para la selección o reducción de features. El resultado de `compare_classes` se expone como el 'Top 10 de features más discriminativas', siendo una herramienta de análisis interpretativo que conecta los hallazgos computacionales con la literatura hematológica

2.10 Modelo de diagnóstico por centroides normalizados

El módulo central del sistema implementa un clasificador no paramétrico basado en distancia euclídea al centroide de cada clase en espacio z-normalizado.

`build_diagnostic_reference()`

Construye el modelo de referencia a partir del DataFrame de 500 imágenes (250/clase). El proceso es el siguiente:

- Selección de features: se seleccionan 21 features con relevancia clínica documentada, priorizando el índice de palidez central, la variabilidad de tamaño, la intensidad y las features de textura GLCM.
- Imputación de valores faltantes: los NaN se reemplazan por la media global de cada feature, estrategia válida para valores ausentes en baja proporción.

- Normalización z-score global: cada feature se estandariza restando la media global y dividiendo por el desvío global (std distinto de 0).
- Cómputo de centroides: en el espacio z-normalizado se calcula el centroide de cada clase como la media de los vectores de features de todas las imágenes de esa clase.

`classify_image_summary()`

Clasifica una imagen nueva calculando su distancia euclídea a los centroides de ambas clases en el espacio z-normalizado. El score anémico se define como:

$$\text{score_anémico} = d_Healthy / (d_Anemic + d_Healthy)$$

donde d_Anemic y $d_Healthy$ son las distancias euclídeas al centroide de cada clase. Esta formulación normaliza el score al intervalo $[0, 1]$: $\text{score} \approx 1$ implica que la imagen es mucho más cercana al centroide anémico; $\text{score} \approx 0$ implica que es mucho más cercana al centroide sano. El umbral de decisión se fija en $\text{THRESHOLD} = 0.48$. El valor fue calibrado empíricamente a partir de la observación de una tendencia de sobreclasificación anémica en el conjunto de validación

2.11 Diagnóstico de imagen nueva

El módulo final integra todo el pipeline en una interfaz de usuario para el entorno Google Colab. Consta de tres funciones. A partir de la imagen cargada por el usuario se clasifica el frotis celular como anémico o sano y se presentan distintas imágenes y medidas estadísticas.

3. Resultados

Para la construcción del modelo de referencia se utilizó un conjunto balanceado de 500 imágenes del subconjunto AneRBC-II (250 Anemic y 250 Healthy). Cada imagen fue procesada mediante el pipeline completo, obteniéndose un vector de características que incluyó parámetros morfológicos, de intensidad, color, textura y conteo celular. El desempeño del clasificador se evaluó sobre un conjunto de validación independiente, compuesto por 250 imágenes de la clase Anemic y 250 imágenes de la clase Healthy, totalizando 500 imágenes no utilizadas en la construcción del modelo de referencia. Para cada imagen se aplicó el pipeline completo y se comparó la clase predicha con la etiqueta real.

El sistema clasificó correctamente 323 de las 500 imágenes evaluadas, alcanzando una exactitud global del 64,6%. Considerando la clase Anemic como clase positiva, se obtuvo una precisión de 0,6034, una sensibilidad de 0,8520, una especificidad de 0,4400 y un F1-score de 0,7065. La matriz de confusión presentó 213 verdaderos positivos, 140 falsos positivos, 37 falsos negativos y 110 verdaderos negativos. Estos resultados muestran que el clasificador tuvo una alta capacidad para detectar imágenes compatibles con patrón anémico, identificando correctamente la mayoría de los casos anémicos del conjunto de validación. Sin embargo, la especificidad fue menor, lo que evidencia una tendencia a clasificar como anémicas algunas imágenes pertenecientes a la clase sana. En consecuencia, el sistema prioriza la sensibilidad frente a la especificidad, comportamiento que puede ser aceptable en una herramienta preliminar de apoyo, pero que requiere ajuste posterior para reducir falsos positivos.

Finalmente, se evaluó el módulo de diagnóstico sobre una imagen nueva cargada por el usuario (Imagen de frotis anémico). El sistema procesó la imagen mediante el pipeline completo, generó la segmentación de eritrocitos, extrajo las características celulares, construyó el descriptor global de la imagen y calculó su distancia a los centroides de referencia. Para la imagen analizada, el modelo predijo la clase Anemic, con una interpretación compatible con patrón anémico. El score anémico obtenido fue de 0,5883, con una confianza relativa de 0,5883. La distancia al centroide Anemic fue de 4,1850, mientras que la distancia al centroide Healthy fue de 5,9802, por lo que la imagen resultó más cercana al grupo anémico en el espacio de características normalizado.

Además, el sistema detectó 84 candidatos celulares y utilizó 81 regiones para la extracción de características. Junto con el resultado numérico, se generaron visualizaciones de la imagen original, la máscara binaria, el mapa de distancia y la segmentación final. Esto permitió verificar que el módulo de diagnóstico integra correctamente las etapas del pipeline y produce una salida interpretable para una imagen externa.




Figura 1. Salidas visuales generadas por el módulo de diagnóstico para una imagen nueva de frotis sanguíneo. (A) Imagen original cargada por el usuario. (B) Imagen con regiones compatibles con eritrocitos detectadas. (C) Máscara binaria obtenida luego del preprocesamiento, umbralización y operaciones morfológicas. (D) Etiquetado de regiones segmentadas. (E) Mapa de distancia utilizado como base para la separación de células en contacto mediante Watershed. (F) Score anémico calculado por el clasificador basado en centroides normalizados. En este caso, el valor obtenido fue 0,588, por lo que la imagen fue clasificada como compatible con patrón anémico.

4. Conclusiones

En este trabajo se logró desarrollar e implementar un pipeline computacional completo para el análisis de imágenes microscópicas de frotis sanguíneo, orientado a la clasificación automática de imágenes compatibles con patrón anémico o sano. El sistema cumplió con los objetivos planteados, ya que permitió realizar el preprocesamiento de las imágenes, segmentar regiones compatibles con eritrocitos, extraer características morfológicas, de intensidad, color, textura y palidez central, agregar dichos parámetros a nivel de imagen y construir un modelo de clasificación binaria basado en centroides normalizados. La validación del clasificador permitió comprobar el funcionamiento general del pipeline sobre imágenes no utilizadas en la construcción del modelo de referencia. El sistema alcanzó una exactitud global del 64,6% y una sensibilidad de 0,8520 para la clase anémica, lo que indica una adecuada capacidad para detectar imágenes compatibles con patrón anémico. Sin embargo, la especificidad obtenida fue menor, evidenciando una tendencia a clasificar algunas imágenes sanas como anémicas. Por lo tanto, el sistema desarrollado debe interpretarse como una herramienta preliminar de apoyo y no como un método diagnóstico definitivo. Como discusión, una de las principales limitaciones del trabajo fue que el modelo se basó únicamente en características extraídas de las imágenes. Además, la segmentación no fue validada contra máscaras manuales realizadas por expertos, por lo que su desempeño fue evaluado principalmente a partir de la coherencia visual y del resultado final de clasificación. A futuro, podrían implementarse mejoras como la optimización del umbral de decisión, la comparación con otros clasificadores clásicos, la validación cruzada, la incorporación de métricas específicas de segmentación y el desarrollo de una interfaz gráfica más completa para facilitar su uso e interpretación.

Anexo

Anexo 1: Parámetros morfológicos clave extraídos de la literatura

Parámetro	Definición - Fórmula	Relevancia Diagnóstica
Área (A)	N.º de píxeles en la región de interés	Microcitosis (A↓): ferropenia, talasemia. Macrocitosis (A↑): déficit de vitamina B12/folatos.
Perímetro (P)	N.º de píxeles en el borde de la célula	Puede aumentar en células con bordes irregulares o proyecciones periféricas, como equinocitos.
Circularidad	$4\pi \cdot A / P^2$ (1 = círculo perfecto)	Aumenta en esferocitos; disminuye en células elongadas o deformadas, como eliptocitos y drepanocitos.
Excentricidad	Relación entre la distancia focal y el eje mayor de la elipse equivalente	Permite identificar células elongadas; valores altos se asocian a eliptocitos, mientras que valores bajos corresponden a formas más circulares.
Solidez	$A / A_{\text{envolvente convexa}}$. Un valor cercano a 1 indica una forma convexa.	Disminuye en células con bordes irregulares o espiculas, como equinocitos y acantocitos; suele ser cercana a 1 en esferocitos.
Palidez central	Contraste entre la zona pálida central y el borde celular.	Se relaciona con hipocromía, ferropenia y talasemias. La ausencia de palidez central puede observarse en esferocitos.
Dimensión fractal (box-counting 3D)	Medida de irregularidad de la superficie en escala de grises, por ejemplo mediante box-counting 3D.	Permite caracterizar variaciones de textura e irregularidad en células patológicas.
Media / Desvío estándar de intensidad	Estadísticas de los valores de píxeles dentro de la región de interés.	Complementan la descripción de la coloración o cromasia eritrocitaria.

Tabla 1.

Parámetros morfológicos eritrocitarios extraídos de la literatura para el diagnóstico diferencial de anemias.

Anexo 2: Materiales y Métodos

Biblioteca / módulo	Función en el proyecto
os, pathlib.Path	Manejo de rutas de archivos multiplataforma
numpy (np)	Operaciones numéricas sobre arrays multidimensionales
pandas (pd)	Manejo de DataFrames para features y resultados
matplotlib.pyplot	Visualización de imágenes y gráficos de diagnóstico
PIL.Image	Carga de imágenes en formato PIL (soporte multi-formato)
cv2 (OpenCV)	Pre-procesamiento: CLAHE, conversiones de color, filtros
scipy.ndimage	Transformada de distancia euclidiana, llenado de huecos
skimage.filters	Umbralización de Otsu
skimage.morphology	Operaciones morfológicas (erosión, cierre, eliminación de objetos)
skimage.measure	Cálculo de propiedades de regiones (regionprops)
skimage.feature	Matriz GLCM y extracción de propiedades de textura
skimage.segmentation	Algoritmo Watershed y clear_border
kagglehub	Descarga automática del dataset desde la API de Kaggle

Tabla 2. Bibliotecas utilizadas y su rol en el pipeline.

Criterio	Umbral	Justificación diagnóstica
Área mínima	80–150 px ²	Descarta artefactos y fragmentos celulares
Área máxima	3000–5000 px ²	Descarta macrocitos atípicos y agregados no separados
Circularidad mínima	0.20–0.45	Descarta fragmentos irregulares y escamas de tinción
Solidez mínima	0.55–0.75	Descarta células con indentaciones profundas atípicas
Excentricidad máxima	0.97–0.99	Descarta objetos muy alargados, no compatibles con RBC

Tabla 3. Criterios de retención compatibles con eritrocitos reales

Categoría	Feature	Descripción
Morfología	area, perimeter, circularity, eccentricity, solidity, extent, orientation	Descriptores de forma geométrica
Tamaño	equivalent_diameter, major_axis_length, minor_axis_length, aspect_ratio	Dimensiones del eje ajustado y diámetro equivalente
Intensidad	mean_gray, std_gray	Media y dispersión del nivel de gris de la célula
Color LAB	mean_L, mean_A, mean_B_lab	Luminosidad y cromacidad en espacio perceptual LAB
Color RGB	mean_R, mean_G, mean_B_rgb	Canales cromáticos en espacio RGB estándar
Palidez	central_pallor_index	Índice de palidez central (diagnóstico de anemia ferropénica)
Textura GLCM	glcm_contrast, glcm_homogeneity, glcm_energy	Descriptores de textura de Haralick

Tabla 4. Vector completo de 22 características extraídas en la etapa de “Extracción de características por célula”.

Estadístico	Notación	Relevancia diagnóstica
Media	feature_mean	Valor central representativo de la distribución de la célula en la imagen
Desvío estándar	feature_std	Variabilidad; indicador de heterogeneidad celular
Mediana	feature_median	Valor central robusto ante valores atípicos
Mínimo	feature_min	Captura células en el extremo inferior de la distribución
Máximo	feature_max	Captura células en el extremo superior de la distribución
Coeficiente de variación	feature_cv = std/mean	Medida normalizada de dispersión; cuantifica anisocitosis y poiquilocitosis

Tabla 5. Los seis estadísticos descriptivos obtenidos en la etapa de agregación por imagen.

Métrica	Fórmula	Interpretación	Positivo=	Relevancia
Accuracy	$(TP+TN) / N$	Proporción global de aciertos	Anemic	Alta
Precision	$TP / (TP+FP)$	Prop. de predicciones anémicas correctas	Anemic	Alta (evita FP)
Recall / Sensibilidad	$TP / (TP+FN)$	Prop. de anémicos detectados	Anemic	Muy alta (diagnóstico)
Especificidad	$TN / (TN+FP)$	Prop. de sanos clasificados correctamente	Anemic	Alta (evita FP)
F1-score	$2 \cdot P \cdot R / (P+R)$	Media armónica de precision y recall	Anemic	Alta (balance)

Tabla 6. Métricas calculadas en la etapa de validación con ground truth.

Bibliografía

- [1] Dumlao, J. (2022). AneRBC: Anemia Diagnosis Using RBC Images. Kaggle Dataset. Disponible en: <https://www.kaggle.com/datasets/jocelyndumlao/anerbc-anemia-diagnosis-using-rbc-images>
- [2] Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6), 610–621.
- [3] Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66.
- [4] Beucher, S., & Lantuéjoul, C. (1979). Use of Watersheds in Contour Detection. *International Workshop on Image Processing: Real-time Edge and Motion Detection/Estimation*.
- [5] van der Walt, S. et al. (2014). scikit-image: image processing in Python. *PeerJ*, 2:e453.
- [6] Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.
- [7] Organización Mundial de la Salud. (2011). Concentraciones de hemoglobina para diagnosticar la anemia y evaluar su gravedad. OMS.
- [8] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.
- [9] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [10] Hernández Merino, A. (2016). *Anemias en la infancia y adolescencia. Clasificación y diagnóstico*. **Pediatría Integral**, XX(5), 287–296.
- [11] Blesa Baviera, L. C. (2016). *Anemia ferropénica*. **Pediatría Integral**, XX(5), 297–307.
- [12] Ventimiglia, F. D., Rivas-Ibargüen, M. A., Vildoza, A., & Orsilles, M. Á. (2017). *Valor diagnóstico de la morfología eritrocitaria en las anemias*. **Acta Bioquímica Clínica Latinoamericana**, 51(3), 379–386.
- [13] Delgado Macías, S., Montenegro Martínez, J., & Pérez Pujalte, S. (2023). *Actualización del diagnóstico diferencial de anemias*. **NPunto**, VI(67), 29–51.
- [14] Mejía, M., Alzate, M., & Rodríguez, J. (2016). *Clasificación automática de glóbulos rojos en frotis de sangre periférica*. **Revista de la Universidad Industrial de Santander. Salud**, 48(3), 311–319. <https://doi.org/10.18273/revsal.v48n3-2016005>
- [15] Mondal, S. K., HasanTalukder, M. S., Aljaidi, M., Sulaiman, R. B., Tushar, M. M. S., & Alsuwaylimi, A. A. (2025). *Efficient blood cell classification from microscopic smear images using U-Net segmentation and a lightweight CNN*. **Scientific Reports**, 15, 45693. <https://doi.org/10.1038/s41598-025-26947-5>
- [16] Organización Mundial de la Salud. (2023). *WHO calls for accelerated action to reduce anaemia*. World Health Organization. <https://www.who.int/news/item/12-05-2023-who-calls-for-accelerated-action-to-reduce-anaemia>